

DATA ANALYTICS

LECCIÓN 2

An abstract digital background with a dark, textured surface. It features glowing white lines, curves, and geometric shapes (squares, circles) that suggest a network or data flow. A faint, glowing rectangular box is visible in the upper left, and a circular icon with three dots is in the lower left. The overall aesthetic is high-tech and futuristic.

LECCION 2

Applied Mathematics and Actuary Training



INFORMACIÓN INICIAL

LECCIÓN 2 – Manipulación de datos

AGENDA DEL TEMA



Limpieza

Corrección de errores y manejo de vacíos.



Transformación

Cambios de escala y normalización.




Fusión

Integración de tablas mediante llaves comunes.



Fuentes

Gestión de archivos de distintos orígenes.



LIMPIEZA DE DATOS

LECCIÓN 2 – Manipulación de datos

TIPOS DE DATOS CRÍTICOS

Los datos crudos suelen presentar inconsistencias que invalidan cualquier modelo estadístico o de IA.

01

Texto e Identificadores

Mayúsculas/minúsculas inconsistentes, espacios extra o errores tipográficos.

02

Valores Numéricos

Valores nulos (NA), outliers extremos o formatos de moneda incompatibles.

03

Categorías

Etiquetas duplicadas con diferentes nombres (ej: "Madrid", "MAD", "madrid").

DESAFÍOS EN EL PERFILADO

01

Registros Duplicados

Entradas idénticas provenientes de errores en la recolección o fusiones previas incorrectas.

02

Valores Faltantes

Celdas vacías que requieren imputación (media, mediana) o eliminación según el impacto.

03

Inconsistencia de Formato

Fechas en formatos heterogéneos (DD/MM/YY vs YYYY-MM-DD) que bloquean series temporales.

04

Ruido y Outliers

Datos fuera de rango lógico (ej: edad = 250) que distorsionan las métricas centrales.

TRATAMIENTO DE VALORES NA

Estrategias fundamentales para gestionar la ausencia de datos en el análisis de variables.

01

Por Lista

Elimina filas completas que contienen valores faltantes. Ideal cuando la pérdida de datos es mínima.

02

Por Columna

Descarta columnas enteras con alto porcentaje de NA para evitar ruido en el modelado.

03

T. Central

Imputa usando media, mediana o moda. Conserva el tamaño de muestra sin alterar la tendencia global.

04

Valor Constante

Sustituye NA por un valor fijo o categoría específica para mantener un indicador explícito de ausencia.

05

Relleno Progresivo

Aplica métodos hacia adelante o atrás (Forward/Backward Fill), óptimos para series temporales estructuradas.



TRANSFORMACIÓN

LECCIÓN 2 – Manipulación de datos

MOLDEANDO EL VALOR

La transformación convierte datos crudos en variables significativas.

01

Normalización

Escalar datos entre 0 y 1 para comparar variables dispares.

02

Codificación

Convertir categorías en valores numéricos (One-Hot, Label).

03

Agregación

Resumir transacciones individuales en métricas por cliente o periodo.

IMPACTO EN MODELOS DE IA

Precisión del Modelo según Nivel de Preparación:

Datos Crudos

45% Accuracy



Solo Limpieza

65% Accuracy

Limpieza + Transf.

88% Accuracy

**Resultados basados en benchmark estándar de regresión logística para predicción de fraude.*



FUSIÓN DE TABLAS

LECCIÓN 2 – Manipulación de datos

LÓGICA DE INTEGRACIÓN (JOINS)



Inner Join

Solo registros con coincidencias en ambas tablas.



Left Join

Todo de la tabla A, coincidente de la tabla B.



Outer Join

Todos los registros de ambas tablas (unión total).




Anti Join

Registros que NO tienen coincidencia.

Concepto de Fusión de Datos

La fusión de tablas permite cruzar múltiples conjuntos de información basándose en campos comunes clave, optimizando la preparación de datos estructurados para análisis avanzados.



TRANSFORMACIONES AVANZADAS

LECCIÓN 2 – Manipulación de datos

TRANSFORMACIONES

CALENDARIO

Variación por efectos simples de tiempo

PRODUCCIÓN TOTAL

Meses con distinta cantidad de días (naturales o hábiles)

MÉTODO

Producción diaria promedio

POBLACIÓN

Datos afectados por cambios estructurales de población

CAMAS HOSPITALES

Región cuya población aumenta a lo largo del tiempo

MÉTODO

Camas por cada 1000 habitantes

FINANZAS / ECO

Datos afectados por valor del dinero

RENTA PROMEDIO

Vivienda a lo largo del tiempo en una región específica

MÉTODO

Valor de la moneda en año específico (INPC)

MATEMÁTICAS

Variaciones que cambian con el nivel de la serie

AUMENTO EXPONENCIAL

Serie cuyo valor crece de forma más pronunciada

MÉTODO

Calcular raíz cuadrada a los datos

¡CUIDADO CON LAS INTERPRETACIONES!