

DATA ANALYTICS

LECCIÓN 5




MODELO SIMPLE

LECCIÓN 5 - Regresión Lineal

Regresión Lineal Simple

Relación paramétrica

$$Y = \beta_0 + \beta_1 X + \varepsilon$$



Y : Variable dependiente o pronóstico

X: Variable independiente o predictora

β_0 : Valor que toma Y con X=0

β_1 : Cambio en Y cada que X aumenta en 1 unidad

Supuestos Fundamentales

- **Linealidad:**
La Relación entre Y y X debe ser lineal.
- **Aleatoriedad:**
X no es estocástica. Aleatoriedad proviene de ε
- **Media cero y Homocedasticidad:**
 $E[\varepsilon] = 0$ $\text{Var}[\varepsilon] = \sigma^2$
- **IID:**
 ε independientes e idénticamente distribuidos
- **Normalidad*:**
Errores ε deben seguir una distribución normal

Modelo Múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

Relación entre una variable dependiente **Y** y múltiples variables explicativas **X_i** simultáneamente.

β_i: Efecto marginal de cada predictor manteniendo todos los demás factores constantes en el modelo.


Riesgos de Ajuste

Sobreajuste (Overfitting)

Memoriza ruido.
Funciona en datos conocidos.
No generaliza.

Subajuste (Underfitting)

Modelo demasiado simple
No captura la estructura.
Alto sesgo y bajo rendimiento.



Estimación

β

Mínimos Cuadrados

Minimizar la suma de los residuos al cuadrado.

Máxima Verosimilitud (MV)

Maximizar la probabilidad de haber observado la muestra actual.



BONDAD DE AJUSTE

LECCIÓN 5 - Regresión Lineal

Métricas de Precisión Predictiva

n : Número de observaciones
 k : Número de predictores del modelo
 L : Logverosimilitud maximizada

R^2

Coeficiente de Determinación

$$R^2 = \frac{\sum(\hat{y} - \bar{y})^2}{\sum(y - \bar{y})^2}$$

Proporción de variación en variable pronóstico explicada por la regresión.

$$0 \leq R^2 \leq 1$$

Entre más grande mejor

R^2 Ajustada

Coeficiente de Determinación Ajustado

$$R^2_a = 1 - \left[\frac{n-1}{n-k-1} \right] (1 - R^2)$$

R^2 incrementa agregando predictores (incluso insignificantes).
 R^2_a compensa.

$$0 \leq R^2_a \leq 1$$

Entre más grande mejor

AIC

Criterio de Información de Akaike

$$AIC = 2k - 2 \ln(L)$$

Penaliza por el número de parámetros k .
Con pocos datos tiende a preferir más predictores.

Menor es mejor

Entre más pequeño mejor

BIC

Criterio de Información Bayesiano

$$BIC = \ln(L) k - 2 \ln(L)$$

Penaliza más fuertemente el número de parámetros k .
Más estricto con sobreajuste en datasets grandes.

Menor es mejor

Entre más pequeño mejor