

DATA ANALYTICS

LECCIÓN 7

Var1

LECCIÓN 7

Applied Mathematics and Actuary Training




OUTLIERS MULTIVARIADOS

LECCIÓN 7 - Detección de Anomalías y Clustering

| ¿Qué es un Outlier Multivariado?

Un dato no siempre es atípico por tener un valor extremo en una sola característica, sino por su **combinación inusual** de variables.

- ✓ **Outlier Univariado:** Una persona con una altura de 2.20 metros (atípico en una sola variable).
- ✓ **Outlier Multivariado:** Una persona de 12 años que mide 1.80 metros y pesa 90 kg. Cada dato por separado es normal, pero la **combinación conjunta** es inusual.



| Detección de Outliers Multivariados



Distancia de Mahalanobis

Mide la distancia de un punto al centroide considerando la correlación entre variables.



Isolation Forest

Algoritmo basado en árboles que "aisla" anómalos rápidamente por requerir menos cortes.



Local Outlier Factor (LOF)

Compara la densidad local de un punto con la densidad de sus vecinos más cercanos.



DBSCAN

Algoritmo de clustering espacial basado en densidad que identifica puntos de baja densidad como anomalías (ruido).

Var1

LECCIÓN 7

Applied Mathematics and Actuary Training




K NEAREST NEIGHBORS

LECCIÓN 7 - Detección de Anomalías y Clustering

| ¿Cómo Funciona KNN?

K-Nearest Neighbors (KNN) es un algoritmo supervisado e intuitivo que clasifica un nuevo punto según la clase mayoritaria de sus K vecinos más cercanos.

- ✓ **Cálculo de Distancia:** Mide la cercanía (habitualmente con Distancia Euclidiana).
- ✓ **Votación Mayoritaria:** Asigna la etiqueta más común entre los vecinos.
- ✓ **Sin Fase de Entrenamiento Pesada:** Es un algoritmo "perezoso" (lazy learner) que almacena los datos y calcula al predecir.



| La Importancia del Parámetro 'K'

A large, bold, red letter 'K' is centered within a dark gray rounded rectangle.

Número de Vecinos

Elegir el valor correcto de K

Si K es muy pequeño (ej. $K=1$): El modelo es muy sensible al ruido y puede sufrir de *overfitting* (sobreajuste).

Si K es muy grande: El modelo se vuelve demasiado general y dominante por la clase mayoritaria, sufriendo de *underfitting*.

Regla general: Usar un número impar para K al clasificar dos categorías para evitar empates en la votación.

Var1

LECCIÓN 7

Applied Mathematics and Actuary Training




DBSCAN

LECCIÓN 7 - Detección de Anomalías y Clustering

| ¿Cómo Funciona DBSCAN?

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa puntos que están densamente amontonados.

- ✓ **Epsilon (ϵ):** La distancia máxima o radio para considerar a otros puntos como vecinos.
- ✓ **MinPts:** El número mínimo de puntos requeridos dentro del radio para formar un grupo denso.
- ✓ **Sin K previo:** No necesitas especificar cuántos clusters existen de antemano.
- ✓ **Detección de Ruido:** Identifica automáticamente los puntos aislados como outliers.



| Tipos de Puntos en DBSCAN



Puntos Núcleo (Core)

Puntos que tienen al menos *MinPts* dentro de su radio *Epsilon*. Son el centro del grupo.



Puntos Borde (Border)

Están dentro del radio de un punto núcleo, pero tienen menos de *MinPts* vecinos propios.



Ruido / Outliers (Noise)

Puntos aislados que no son ni núcleo ni borde. Se marcan directamente como anomalías.